Tecnológico de Monterrey

Actividad 9

Regresión logística multinomial

Análitica de datos y herramientas de inteligencia artificial

10 de noviembre de 2026

Rodrigo Zapien Barrios | A01424400

1. Introducción

El análisis usa la hoja Negocios del CRM proporcionada por CLV (5,268 negocios). En este análisis la variable objetivo es el resultado del negocio, explicado por tres variables categóricas:

Rol	Variable	Categorías
Objetivo	resultado	Ganado / Perdido / Abierto
Explicativa 1	pipeline_grp	Pipeline De Ventas / Ventas - Main / Mapeo-Educación
Explicativa 2	cat_actividades	Sin actividad / 1-2 / 3 o más (creada a partir de numero_actividades)
Explicativa 3	tipo_negocio_grp	Cliente existente / Cliente nuevo / Sin dato

Se analiza cada explicativa por separado (modelos A, B y C) y las tres juntas (modelo D).

2. Preprocesamiento: nulos, outliers y transformaciones

Se conservaron 5,245 de 5,268 negocios (99.6%); el cambio más importante fue detectar que 1,661 negocios (31.7%) tienen la fecha de cierre registrada antes de la creación o les falta alguna fecha.

Nulos y registros inválidos

Problema	Casos	Tratamiento
Columna `Unnamed: 19` (99.73% nula)	1 columna	No se usa; es un residuo del archivo
Filas desalineadas (texto recorrido de columna: una fecha en numero_actividades, "Cerrado" en fecha_creacion)	6	Eliminadas
numero_actividades o valor_negocio vacíos	17	Eliminadas (junto con las 6 anteriores suman 23)
fecha_creacion no convertible	30	Trimestre de creación = "Sin dato"
tipo_negocio vacío o fuera de catálogo	—	Categoría "Sin dato"

Outliers y transformaciones

- **numero_actividades**: máximo original de 123; se topó en el percentil 99 (8 actividades) y después se convirtió en la categórica cat_actividades.
- **valor_negocio**: mediana 0, alrededor de 80% de ceros y máximo de 6.9 millones. Se transformó con log(1 + x) para reducir el sesgo.
- **valor_previsto**: sus estadísticos son prácticamente idénticos a los de valor_negocio (colinealidad), por lo que no aporta información adicional.

- **Escalado**: las variables dummy de cada modelo se estandarizaron con `StandardScaler`, ajustado solo con el conjunto de entrenamiento (igual que en el notebook base).

Duración del ciclo e indicador de registro retroactivo

La duración se calculó en días con decimales (fecha_cierre − fecha_creacion). Se encontraron 2,085 negocios con cierre anterior a la creación:

- **516 con menos de 1 día de diferencia**: son negocios registrados ya cerrados en el mismo instante (segundos de diferencia). Se tomaron como duración 0.
- **1,569 con 1 día o más**: el negocio se dio de alta en el CRM después de cerrarse. Junto con 92 negocios sin alguna fecha suman 1,661 duraciones no válidas.

Las 1,661 duraciones se imputaron con la mediana y se creó la variable indicadora registro_retroactivo (1 = registro retroactivo o sin fecha). Las duraciones válidas se toparon en el percentil 99 (145.9 días).

Los modelos finales usan solo las tres explicativas categóricas. El valor, la duración y el indicador de registro retroactivo no entran en ellos, pero se reportan porque describen la calidad de los datos y ayudan a interpretar los resultados.

3. Variables del análisis y conversión a categóricas

La variable objetivo y las tres explicativas se construyeron agrupando categorías con sentido de negocio, cuidando que ninguna categoría quedará demasiado pequeña.

Rol	Variable	Regla de construcción	Categorías (negocios)
Objetivo	resultado	Cierre Ganado + Ganado = Ganado; Cierre Perdido + Perdido = Perdido; etapas intermedias = Abierto	Ganado 4,099 · Perdido 934 · Abierto 212
Explicativa 1	pipeline_grp	Educación Contínua (24 negocios) se unió con Mapeo En Ruta por ser muy pequeña	Pipeline De Ventas 4,385 · Ventas - Main 719 · Mapeo-Educación 141
Explicativa 2	cat_actividades	numero_actividades (numérica) en cortes: 0 = sin seguimiento, 1-2 = seguimiento ligero, 3 o más = seguimiento intenso	Sin actividad 3,666 · 1-2 1,147 · 3 o más 432
Explicativa 3	tipo_negocio_grp	Nulos y valores fuera de catálogo = Sin dato	Cliente existente 3,817 · Cliente nuevo 888 · Sin dato 540

Las explicativas se convirtieron en variables dummy. La primera categoría de cada una queda como referencia y los coeficientes se leen contra ella: Pipeline De Ventas, Sin actividad y Cliente existente (las más comunes).

No se usaron estatus, nombre_etapa ni motivo_cierre_perdido porque definen el resultado (fuga de información).

4. Metodología del modelado

El análisis tiene dos partes: primero se mide la asociación de cada explicativa con el resultado, y después se entrenan cuatro modelos de regresión logística multinomial.

Asociación (antes de modelar)

- **Tabla de contingencia**: qué porcentaje de cada categoría se gana, se pierde o sigue abierto.
- **Prueba chi-cuadrada**: un valor p menor a 0.05 indica que la relación no se debe al azar.
- **V de Cramér**: fuerza de la relación entre dos categóricas, de 0 (ninguna) a 1 (total). Como guía: 0.1 débil, 0.3 moderada, 0.5 o más fuerte.

Modelos

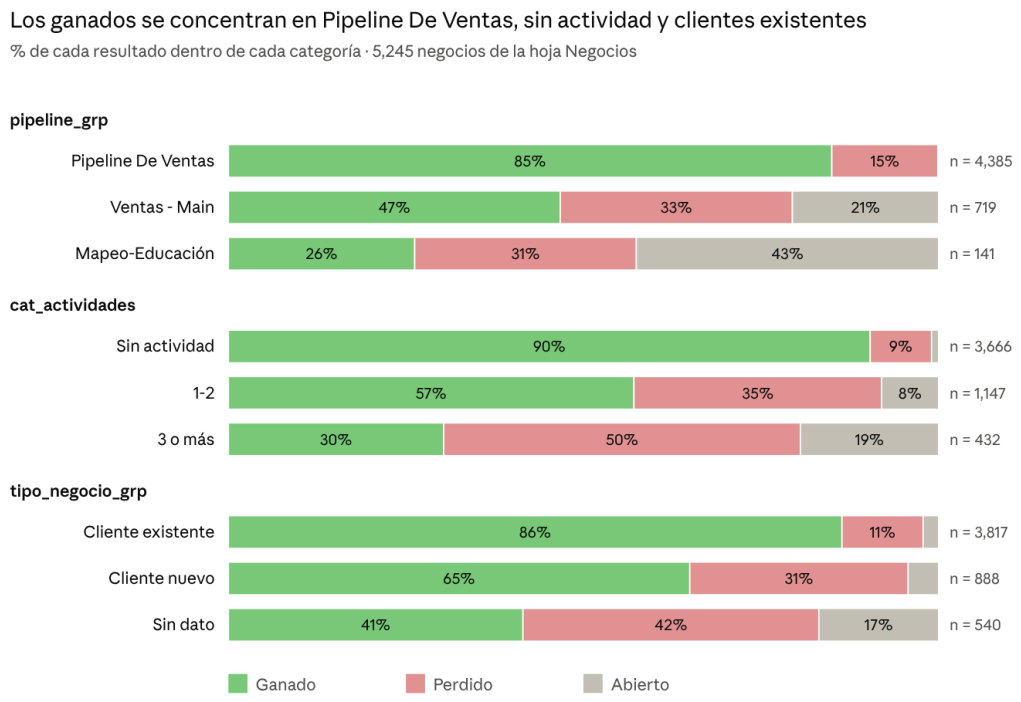
Modelo	Variable objetivo	Explicativa(s)
A	resultado	pipeline_grp
B	resultado	cat_actividades
C	resultado	tipo_negocio_grp
D	resultado	pipeline_grp + cat_actividades + tipo_negocio_grp

Cada modelo sigue el procedimiento del notebook base: `Vars_Indep` y `Var_Dep`, división 70/30 estratificada (`random_state=42`, 1,574 negocios de prueba), `StandardScaler` y `LogisticRegression(solver='lbfgs', max_iter=1000)`. Cada modelo se entrenó dos veces:

- **Sin ajuste**: todos los errores pesan igual.
- **Con reponderación** (`class_weight='balanced'`): cada clase pesa en proporción inversa a su tamaño. Un error en un negocio abierto pesa unas 19 veces más que uno en un ganado, porque hay 19 veces menos abiertos. Así el modelo no puede ignorar las clases pequeñas.

5. Asociación de cada explicativa con el resultado

Las tres explicativas están asociadas con el resultado ($p < 0.001$ en las tres) y con fuerza moderada: el pipeline es la más fuerte (V de Cramér 0.373), seguida de las actividades (0.347) y el tipo de negocio (0.266).



Explicativa	Chi-cuadrada	gl	Valor p	V de Cramér	Fuerza
pipeline_grp	1,462.9	4	< 0.001	0.373	Moderada
cat_actividades	1,260.3	4	< 0.001	0.347	Moderada
tipo_negocio_grp	741.6	4	< 0.001	0.266	Débil a moderada

Qué muestra cada relación

- **Pipeline**: Pipeline De Ventas casi no tiene negocios abiertos (4 de 4,385) y gana 85%. Ventas - Main y Mapeo-Educación concentran los abiertos (148 y 60) y ganan mucho menos (47% y 26%). Pipeline De Ventas se comporta como un registro de ventas ya cerradas.
- **Actividades**: entre más actividades, menos ganados y más perdidos. Sin actividad gana 90% y pierde 9%; con 3 o más actividades gana 30% y pierde 50%. No significa que el seguimiento haga perder ventas: los negocios difíciles reciben más seguimiento, y muchas ventas ganadas se registran sin actividades.
- **Tipo de negocio**: los clientes existentes ganan 86%, los nuevos 65%. Los negocios sin tipo registrado ganan solo 41.5% y tienen 17% de abiertos: los registros incompletos se asocian con peores resultados.

6. Modelos A, B y C: cada explicativa por separado

Por separado, ninguna explicativa mejora de forma clara la línea base de 78.2%: el modelo A llega a 78.8%, el B a 80.0% y el C a 78.1%. Con una sola variable de 3 categorías, el modelo solo puede asignar una clase a cada categoría, y "Ganado" es la más común en casi todas.

Por eso cada modelo aprende una regla sencilla (qué clase predice para cada categoría), deducida de sus matrices de confusión:

Modelo	Versión	Regla aprendida
A: pipeline_grp	Sin ajuste	Mapeo-Educación → Abierto; los otros dos pipelines → Ganado
A: pipeline_grp	Con reponderación	Mapeo-Educación y Ventas - Main → Abierto; Pipeline De Ventas → Ganado
B: cat_actividades	Sin ajuste	3 o más → Perdido; Sin actividad y 1-2 → Ganado
B: cat_actividades	Con reponderación	1-2 y 3 o más → Abierto; Sin actividad → Ganado
C: tipo_negocio_grp	Sin ajuste	Sin dato → Perdido; clientes existentes y nuevos → Ganado
C: tipo_negocio_grp	Con reponderación	Sin dato → Abierto; Cliente nuevo → Perdido; Cliente existente → Ganado

Modelo A: resultado ~ pipeline_grp

Sin ajuste (filas = real)	Pred. Abierto	Pred. Ganado	Pred. Perdido
Abierto (64)	23	41	0
Ganado (1,230)	12	1,218	0
Perdido (280)	13	267	0

Con reponderación (filas = real)	Pred. Abierto	Pred. Ganado	Pred. Perdido
Abierto (64)	63	1	0
Ganado (1,230)	97	1,133	0
Perdido (280)	89	191	0

Clase	Precisión sin ajuste	Sensibilidad sin ajuste	Precisión con reponderación	Sensibilidad con reponderación
Abierto	0.479	0.359	0.253	0.984
Ganado	0.798	0.990	0.855	0.921
Perdido	0.000	0.000	0.000	0.000
Exactitud	**0.788**		**0.760**	

El pipeline sirve para **encontrar negocios abiertos**: con reponderación detecta 63 de 64. Pero no detecta ningún perdido, porque en ningún pipeline los perdidos son mayoría.

Modelo B: resultado ~ cat_actividades

Sin ajuste (filas = real)	Pred. Abierto	Pred. Ganado	Pred. Perdido
Abierto (64)	0	38	26
Ganado (1,230)	0	1,194	36
Perdido (280)	0	215	65

Con reponderación (filas = real)	Pred. Abierto	Pred. Ganado	Pred. Perdido
Abierto (64)	51	13	0
Ganado (1,230)	211	1,019	0
Perdido (280)	183	97	0

Clase	Precisión sin ajuste	Sensibilidad sin ajuste	Precisión con reponderación	Sensibilidad con reponderación
Abierto	0.000	0.000	0.115	0.797
Ganado	0.825	0.971	0.903	0.828
Perdido	0.512	0.232	0.000	0.000
Exactitud	**0.800**		**0.680**	

Sin ajuste, las actividades son la única explicativa que por sí sola detecta perdidos (65 de 280, con precisión de 0.51). Con reponderación el modelo cambia esos negocios a "Abierto" y deja de detectar perdidos: la exactitud baja a 68.0%. Para esta variable, la versión sin ajuste es más útil.

Modelo C: resultado ~ tipo_negocio_grp

Sin ajuste (filas = real)	Pred. Abierto	Pred. Ganado	Pred. Perdido
Abierto (64)	0	41	23
Ganado (1,230)	0	1,154	76
Perdido (280)	0	205	75

Con reponderación (filas = real)	Pred. Abierto	Pred. Ganado	Pred. Perdido
Abierto (64)	23	29	12
Ganado (1,230)	76	989	165
Perdido (280)	75	117	88

Clase	Precisión sin ajuste	Sensibilidad sin ajuste	Precisión con reponderación	Sensibilidad con reponderación
Abierto	0.000	0.000	0.132	0.359
Ganado	0.824	0.938	0.871	0.804
Perdido	0.431	0.268	0.332	0.314
Exactitud	**0.781**		**0.699**	

El tipo de negocio es la explicativa más débil: sin ajuste queda igual que la línea base. Es el único modelo individual que, con reponderación, predice las tres clases, aunque con sensibilidades bajas para abiertos (0.36) y perdidos (0.31).

7. Modelo D: las tres explicativas juntas

Juntas, las tres variables se complementan: el modelo D sin ajuste acierta 82.2% (+4.0 puntos sobre la línea base) y es el único que detecta las tres clases a la vez. El pipeline aporta la detección de abiertos, y las actividades y el tipo de negocio la de perdidos.

Sin ajuste (filas = real)	Pred. Abierto	Pred. Ganado	Pred. Perdido
Abierto (64)	8	27	29
Ganado (1,230)	0	1,155	75
Perdido (280)	3	146	131

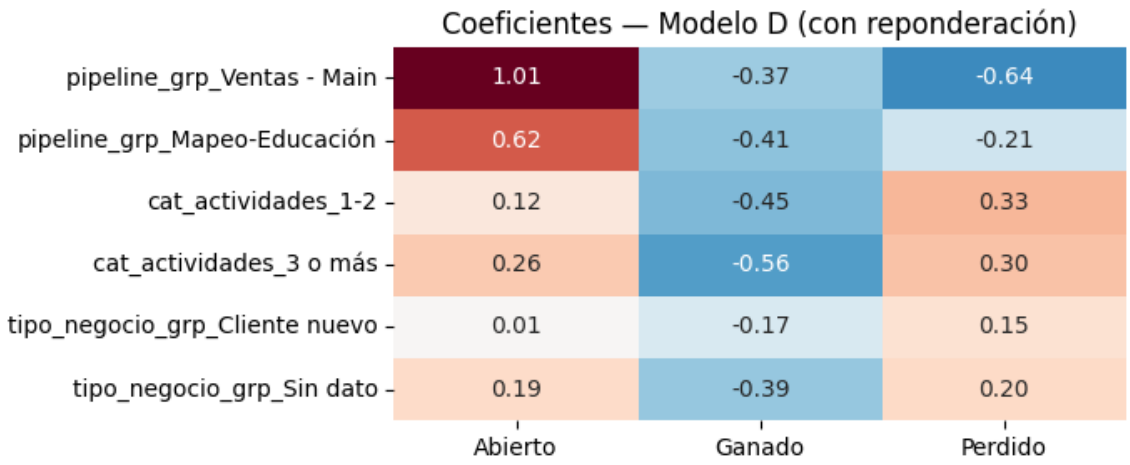
Con reponderación (filas = real)	Pred. Abierto	Pred. Ganado	Pred. Perdido
Abierto (64)	63	0	1
Ganado (1,230)	97	958	175
Perdido (280)	89	76	115

Clase	Precisión sin ajuste	Sensibilidad sin ajuste	Precisión con reponderación	Sensibilidad con reponderación
Abierto	0.727	0.125	0.253	0.984
Ganado	0.870	0.939	0.926	0.779
Perdido	0.557	0.468	0.395	0.411
Exactitud	**0.822**		**0.722**	

Sin ajuste vs. con reponderación

- **Sin ajuste**, el modelo detecta 131 de 280 perdidos (47%) con buena precisión (0.56), la mejor cifra de todos los modelos. Pero casi no reconoce los abiertos: solo 8 de 64.
- **Con reponderación**, encuentra 63 de 64 abiertos y 41% de los perdidos. El costo: 97 ganados se marcan como abiertos y 175 como perdidos, y la exactitud baja a 72.2%, por debajo de la línea base.

Coeficientes del modelo con reponderación (contra Pipeline De Ventas, Sin actividad y Cliente existente)

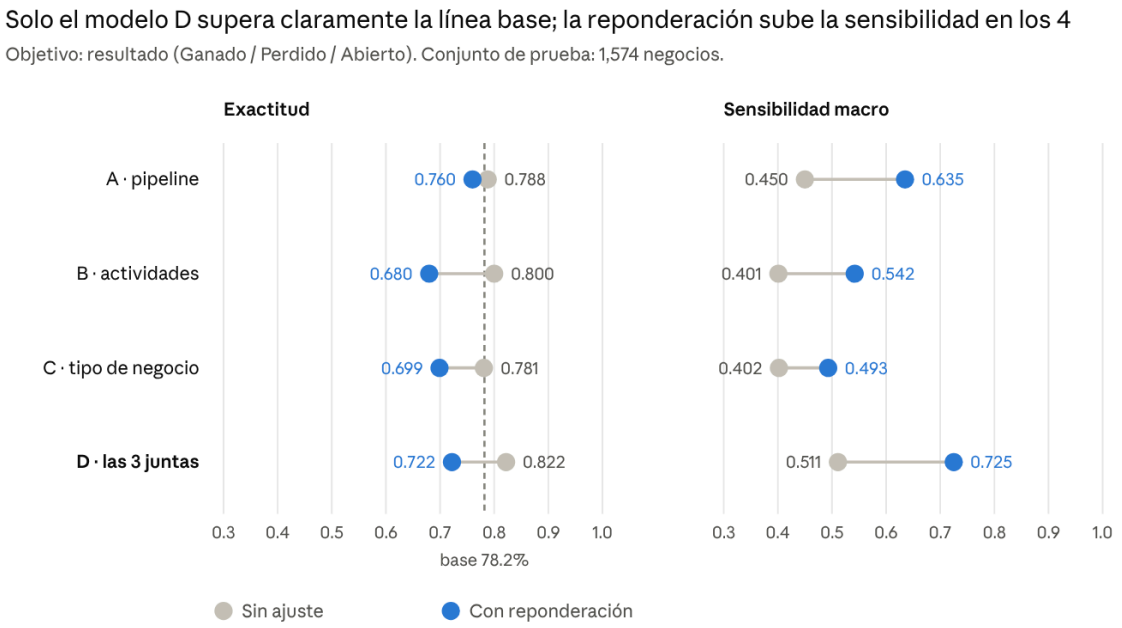


- **Ventas - Main** es la señal más fuerte de negocio abierto (+1.01) y reduce la probabilidad de perdido (−0.64). En la tabla de contingencia Ventas - Main tenía 33% de perdidos; una vez que el modelo considera las actividades, esos perdidos se explican por el seguimiento y no por el pipeline.

- **Mapeo-Educación** también aumenta la probabilidad de abierto (+0.62) y reduce la de ganado (−0.41).
- **Tener actividades** (1-2 o 3 o más) reduce la probabilidad de ganado (−0.45 y −0.56) y aumenta la de perdido (+0.33 y +0.30).
- **Sin dato en tipo de negocio** reduce la probabilidad de ganado (−0.39) y aumenta la de abierto y perdido (+0.19 y +0.20). Ser **cliente nuevo** tiene un efecto pequeño en la misma dirección (−0.17 ganado, +0.15 perdido).

8. Comparación de los 4 modelos

Solo el modelo D supera claramente la línea base (82.2% contra 78.2%). En los cuatro modelos, la reponderación baja la exactitud y sube la sensibilidad macro: el modelo D con reponderación tiene la sensibilidad macro más alta (0.725).



Métricas complementarias

Modelo	Versión	Precisión ponderada	Sensibilidad ponderada	Precisión macro	F1 ponderado
A: pipeline_grp	Sin ajuste	0.643	0.788	0.426	0.707
A: pipeline_grp	Con reponderación	0.678	0.760	0.369	0.709
B: cat_actividades	Sin ajuste	0.736	0.800	0.446	0.754
B: cat_actividades	Con reponderación	0.710	0.680	0.339	0.683

Modelo	Versión	Precisión ponderada	Sensibilidad ponderada	Precisión macro	F1 ponderado
C: tipo_negocio_grp	Sin ajuste	0.721	0.781	0.418	0.745
C: tipo_negocio_grp	Con reponderación	0.745	0.699	0.445	0.719
D: las 3 juntas	Sin ajuste	0.808	0.822	0.718	0.805
D: las 3 juntas	Con reponderación	0.805	0.722	0.525	0.749

¿Qué versión usar? Depende del objetivo del socio formador. Para acertar en general y detectar negocios en riesgo de perderse con pocas falsas alarmas, el modelo D sin ajuste (F1 ponderado 0.805, el más alto). Para no dejar pasar ningún negocio abierto, el modelo D con reponderación, aceptando más negocios marcados de más.

9. Conclusiones

El pipeline, el nivel de seguimiento y el tipo de cliente están relacionados con el resultado de los negocios, pero ninguno lo explica por sí solo. Combinados, permiten anticipar mejor qué negocios siguen abiertos y cuáles tienen riesgo de perderse.

1. **Las tres variables están asociadas con el resultado.** Las tres pruebas chi-cuadrada tienen $p < 0.001$. El pipeline es la más fuerte ($V = 0.373$), seguida de las actividades (0.347) y el tipo de negocio (0.266).
2. **Por separado, ninguna predice bien.** Los modelos A, B y C quedan a menos de 2 puntos de la línea base. Cada una ayuda con una sola clase: el pipeline encuentra abiertos, y las actividades y el tipo de negocio encuentran perdidos.
3. **Juntas se complementan.** El modelo D acierta 82.2% (+4.0 puntos), tiene el F1 ponderado más alto (0.805) y es el único que detecta las tres clases. Detecta 47% de los perdidos con precisión de 0.56.
4. **La reponderación cambia exactitud por cobertura.** En el modelo D detecta 63 de 64 abiertos, pero marca de más a 272 ganados y la exactitud baja a 72.2%. La versión a usar depende de qué error le cuesta más al socio formador.

Lecturas generales

- **Pipeline De Ventas funciona como registro de ventas cerradas**: gana 85% y casi no tiene negocios abiertos (4 de 4,385). El trabajo comercial en curso está en Ventas - Main y Mapeo-Educación.
- **Los negocios con más actividades se pierden más** (50% con 3 o más actividades, contra 9% sin actividad). Esto no indica que el seguimiento haga perder ventas: los negocios difíciles reciben más seguimiento, y muchas ventas ganadas se registran sin actividades (un tercio de los negocios se dio de alta después de cerrarse).
- **Los clientes nuevos se pierden casi tres veces más que los existentes** (31% contra 11%), y los negocios sin tipo registrado tienen los peores resultados (41.5% ganados).

10. Limitaciones

Los resultados describen asociaciones en los datos del CRM, no causas, y dependen de la calidad con que se capturan los negocios.

- **Pocas explicativas**: por diseño se usan sólo tres categóricas. Un modelo con una sola variable de 3 categorías sólo puede asignar una clase a cada categoría, por eso los modelos A, B y C casi no superan la línea base.
- **Registro retroactivo**: 31.7% de los negocios se dio de alta después de cerrarse o le falta una fecha. Esto afecta sobre todo la lectura de las actividades.
- **Desbalance de clases**: solo 64 negocios abiertos en el conjunto de prueba. Con reponderación, la precisión de Abierto queda entre 0.12 y 0.25.
- **Una sola división entrenamiento/prueba**: con validación cruzada, las métricas de las clases pequeñas serían más estables.